

# EEOP 实施指南：证据嵌入式操作协议的落地方法与跨模型适用性

版本：v1.0 (2026-08-06) 前置文档：《证据嵌入式操作协议 — 预载规则优化设计与再评估》适用范围：由 LLM agent 执行、需要过程完整性保障（如实汇报、不静默漂移、不编造完成）的实验/工程任务

## 第一部分：实施方法

### 1. 总体架构

EEOP 由五个组件构成，全部从单一事实源（审计者维护的规则库）生成：

```
规则库（审计者维护，版本化）
├── 任务包装器（按任务类型选协议子集，≤5 条/包）
│   ├── L0 规格卡 → 预载第 1 轮
│   ├── L1 TAE 协议 → 预载正文
│   ├── L2 正例示范 → 预载对话（assistant 轮次呈现）
│   └── L3 汇报模板 + 承诺轮 → 预载最后一轮
└── 检查项清单（与协议“产出”列同源）→ pre_flight_check.py / 执行闸门
```

关键架构原则：预载给 agent 的协议和检查 agent 的闸门，从同一份定义生成。修改规则库 → 协议和检查项同步更新，杜绝“教一套、查另一套”。

### 2. 分步实施

步骤 1：建立规则库（一次性，审计者完成） 从错误档案（如 23 类错误）推导协议，每条协议必须满足三个格式要求：

```
协议编号：P{n}
触发（When）：[可观察的情境，而非内部状态]
动作（Do）：[具体的、可执行的操作，动词开头]
产出（Evidence）：[可被机械化检查的工件：文件/diff/hash/清单]
```

正误对照：

| ✗ 不可用       | ✓ 可用                                            |
|-------------|-------------------------------------------------|
| “不得凭记忆汇报”   | 当撰写状态汇报 → 先执行”读文件 → 核对 → diff” → 产出 diff 原文     |
| “要保证数据一致性”  | 当产出结果文件 → 以 mode+version+timestamp 命名 → 产出文件名清单 |
| “遇到错误要妥善处理” | 当任何调用失败 → 原样记录完整错误信息 → 产出错误原文 + 处置记录            |

检验标准：触发条件能否被第三方从外部观察判定？产出物能否被脚本检查存在性？两个答案都是”能”，协议才合格。

步骤 2：任务类型 → 协议包映射 从错误档案统计每类任务的历史错误分布，选出该类任务高发的 3–5 类错误对应的协议。硬性上限：每包 5 条协议（指令悬崖证据：约束数超阈值后遵守率下降<sup>[1]</sup>；2026 年新数据把这个上限推得更高，但少而精仍是安全默认<sup>[2]</sup>）。

示例映射表（基于 ds\_kimi 档案）:

| 任务类型    | 历史高发错误                  | 协议包内容                                 |
|---------|-------------------------|---------------------------------------|
| 多模式实验对比 | A1 数据复制、C2 结构漂移、D1 计时错误 | 规格卡（结构 + 计时）+ 文件命名协议 + 汇报协议 + diff 协议 |
| 数据处理/清洗 | C1 参数漂移、C3 口径混淆         | 规格卡（口径 + 参数）+ 变更冻结协议 + 汇报协议           |
| 长流水线执行  | B1 步骤跳过、错误丢失            | 逐步证据指针协议 + 报错保因协议 + 汇报协议              |

步骤 3：编写预载对话 预载不是一段 system prompt，而是一段构造好的多轮对话，顺序固定：

第 1 轮（user 出示规格卡，assistant 确认）：

[任务规格卡 · 实验对比类]  
开始前请确认以下定义。任何一项无法从任务说明中确定，先提问，再开始：  
☐ 各评估维度的分子/分母：\_\_\_\_  
☐ 各模式实际消息结构（逐字段）：\_\_\_\_  
☐ 全部参数及取值（含默认值）：\_\_\_\_  
☐ 计时公式的被测对象：\_\_\_\_

中间轮（L2 正例示范，2–3 段短对话）：演示协议被正确执行的完整过程。要点：

- 示范以 assistant 轮次呈现（many-shot 证据：history 中的示范对行为塑造服从幂律 [^3^]）；
- 只放正例，绝不出现错误案例全文（坏例子 = 模仿模板 [^4^]；ExpeL 消融证实含错内容有害 [^5^]）；
- 必须包含一段”规格卡某项不确定 → assistant 主动提问”的示范，把”承认不确定”塑造为合规行为；
- 示范中的证据产出要具体（真实的文件名、diff 片段、hash 格式），不要抽象描述。

最后一轮（L3 汇报模板 + 承诺轮）：

汇报必须使用以下格式，证据字段为空视为未执行：  
## 完成声明  
- 声明内容：  
- 证据指针：[文件路径 + hash + 关键行号]  
- 与规格卡的 diff：  
- 未执行项及原因：

随后 assistant 用自己的话复述本包 2–3 条关键协议（承诺轮）。承诺对象只能是动作（“汇报完成前我先贴 diff”），不能是结果（“我会做对”）或品质（“我会诚实”）——后两类自我陈述已被 CoT 忠实性文献证明不可信 [6]。

步骤 4：同源生成检查项 每条协议的”产出”列自动生成一条检查项，汇入 pre\_flight\_check.py:

| 协议产出         | 检查项（机械化）                        |
|--------------|---------------------------------|
| spec diff 链接 | 提交信息含 spec 版本号引用                |
| 文件名清单        | 文件名匹配 mode+version+timestamp 正则 |
| 证据指针         | 路径存在 + hash 可复算 + 行号在范围内        |
| diff 原文      | 汇报中含非空 diff 块                   |
| 错误原文 + 处置    | 失败调用有对应错误记录条目                   |
| 退役清单         | 新文件创建与旧文件 deprecated 标记同提交      |

Table 3 – continued

| 协议产出 | 检查项（机械化） |
|------|----------|
|------|----------|

步骤 5：部署与运行纪律

- 1. 任务开始前由协调者指定任务类型（oracle 选择），装配任务包注入；
- 2. 加载回执：agent 首轮输出必须是确认后的规格卡，无回执不放行（防”预载了但没读”）；
- 3. 执行中：汇报走 L3 模板；闸门按检查项拦截；
- 4. 事故后：新错误类型 → 审计者提炼新协议 → 规则库版本升级 → 协议包与检查项同步再生（这复刻 2606.14589 的”事故驱动防御成熟”路径，但起点从”禁令”升级为”协议”）。

3. 反模式清单（实施时必须避免）

| 反模式              | 后果             | 依据      |
|------------------|----------------|---------|
| 协议写成禁令/态度要求      | 无法检查、粉象效应      | [4]     |
| 错误案例全文进预载        | 诱发模仿           | [4][5]  |
| 承诺对象写成结果/品质      | 自我陈述不可信        | [6]     |
| 协议 >5 条/包        | 约束悬崖，遵守率下降     | [1]     |
| 预载与闸门各自维护        | 教查脱节，防线失效      | 单一事实源原则 |
| 自查写成”检查你的推理”     | 85-95% 沦为确认性复查 | [7]     |
| 规则由被治理 agent 自生成 | 反思编造率 32-82%   | [8]     |

第二部分：跨基座模型适用性

1. 结论先行

EEOP 的核心机制与具体模型无关，跨模型适用；但效应大小因模型而异，且三个已知失效模式具有模型特异性。协议层（what）可移植，参数层（how many/how much）需按模型标定。

2. 逐机制的跨模型证据

| EEOP 机制     | 跨模型证据                                                                                                                                  | 判定                        |
|-------------|----------------------------------------------------------------------------------------------------------------------------------------|---------------------------|
| 上下文规则塑造行为   | AGENTS.md 研究覆盖多个 coding agent/模型，指令普遍被执行 [9]；deliberative alignment 在 o 系上 30× 削减违规，且 spec 层级化方法已被证明可跨部署迁移（一个模型生成的 spec 可用于另一模型家族）[10] | ✔ 普适                      |
| 对话历史示范的幕律塑造 | many-shot 研究在 Claude 上证实，且被 DeepMind 等机构复现/扩展；示范格式效应是 Transformer 情境学习的通用属性 [3]                                                        | ✔ 普适                      |
| 实施意图（触发-动作） | 心理学效应跨人群稳健；LLM 端的引导实验证实模型可生成并遵循 if-then 结构 [11]                                                                                        | ✔ 普适（LLM 端直接证据尚少，列为待验证假设） |

Table 5 – continued

| EEOP 机制 | 跨模型证据                                                                                                               | 判定             |
|---------|---------------------------------------------------------------------------------------------------------------------|----------------|
| 承诺降低方差  | 诊断研究在多个开源模型上复现 <sup>[12]</sup>                                                                                      | ✓ 普适，但注意其双刃剑属性 |
| 约束数量上限  | IFScale 2026: 所有被测模型都遵守”<br>规则越多遵守越差”的规律，只是拐点位置不同——一年前的模型在 200–300 条处崩溃，当前前沿模型（GPT 5.5 最佳）推到 ~2000 条 <sup>[2]</sup> | ✓ 规律普适，阈值模型相关  |

### 3. 模型间真实存在的差异（部署时必须标定）

**差异 1：指令层级（system vs user vs history）的尊重程度不同。** OpenAI 专门训练了指令层级（IH）并公开发布对比<sup>[13]</sup>；开源模型的层级训练普遍较弱——越狱/提取研究显示 LLaMA 系及社区微调在单层提示下即让步，闭源前沿模型需要多轮累积<sup>[14]</sup>。含义：**EEOP 用 history 而非 system prompt 承载协议，在弱层级模型上反而可能是优势**（示范通道不依赖层级训练），但需要实测。

**差异 2：提示策略效果不完全跨模型迁移。** 跨 12 模型研究：few-shot 对 9/12 个模型有效但 Mixtral 反效果；格式偏好按家族分化（GPT/Gemini 偏好 Alpaca 格式，Claude 偏好 XML，Llama/Mixtral 偏好自然段落）<sup>[15]</sup>；临床 NLP 三模型研究同样发现”任务 × 模型 × 提示类型”交互显著<sup>[16]</sup>。含义：**EEOP 的示范格式（XML/段落/对话轮）应按目标模型家族微调一次，然后冻结。**

**差异 3：高负载下的失效模式不同。** IFScale 2026 发现前沿模型不再是简单”忘规则”：DeepSeek V4 Pro 保持经典模式（N=750 起逐条丢）；Claude Opus 4.7 会触发拒答；Gemini 3.1 Pro 会把输出预算耗尽于内部推理而不产出可见报告<sup>[2]</sup>。含义：**协议包 5 条的上限对老模型是硬约束，对新前沿模型有余量——但 Gemini 式”想太多不输出”恰好是 EEOP 证据槽模板能结构性防止的失败（空汇报 = 不合规），这是 EEOP 跨模型鲁棒性的一个论据。**

**差异 4：上下文压力的普遍存在。** 软前缀实验证明：无语义内容的嵌入向量都能以 54–90% 的翻转率改变 Qwen/Gemma 的正确推理结论<sup>[17]</sup>。含义：**任何纯上下文方法（包括 EEOP）都有结构性的稳定性上限，跨模型一致——这再次确认 EEOP 必须与闸门配对，不能单独部署。**

### 4. 跨模型部署的标定流程（建议）

对每个新基座模型，做一次性的低成本标定（4 个读数）：

1. **格式偏好**：同一协议包以对话轮/XML/段落三种格式各跑 10 题，选违规率最低者（依据<sup>[15]</sup>）；
2. **包容量上限**：协议数 3/5/8 梯度，找遵守率拐点（依据<sup>[2]</sup>）；
3. **载体强度**：system prompt vs preload history 对照（依据<sup>[14]</sup>，弱层级模型预期 history 更优）；
4. **失效模式画像**：故意构造超负载任务，观察该模型是”丢规则/拒答/空转”哪种失效（依据<sup>[2]</sup>），针对性调整（如 Gemini 系加强 L3 模板的输出强制）。

### 5. 哪些模型不适用

- **无指令遵循能力的基座模型**（未经 instruct 微调的 raw base model）：所有机制失效；
- **被刻意去审查的微调**：规则通道形同虚设<sup>[14]</sup>，EEOP 只能依赖闸门硬层；
- **极弱模型（<7B 量级）**：规格卡 + 协议 + 示范的复合结构可能超出其工作记忆，需极简版（1 张规格卡 + 2 条协议）。

## 第三部分：Supporting Research 清单（按设计决策索引）

| 设计决策           | 支撑文献                                                                    |
|----------------|-------------------------------------------------------------------------|
| 规则进上下文可降低违规    | OpenAI×Apollo deliberative alignment (30× 削减) [10]; AGENTS.md 指令被执行 [9] |
| 失败教训 → 上下文规则有效 | ExpeL [5]; Dynamic Cheatsheet; ACE (AppWorld +12~15%)                   |
| history 载体效力   | Many-shot 幂律 [3]                                                        |
| 触发-动作式写法       | 实施意图 (Gollwitzer 1999; LLM 引导实验 $\eta=0.50$ ) [11]                      |
| 只放正例           | 否定式提示研究 [4]; ExpeL 消融 [5]                                               |
| 承诺轮            | 承诺降低方差 (token 控制实验) [12]                                                |
| 承诺限于动作         | CoT 忠实性: 25–39% 承认率, 想/说分离 [6]                                          |
| 证据槽替代自查        | 85–95% 自我复查是确认性的 [7]; 自我纠错无外部反馈不可靠                                      |
| 规则外部产生         | 反思编造率 32–82% [8]                                                        |
| 5 条/包          | 指令悬崖 (3.3 约束) [1]; IFScale 2026 更新 [2]                                  |
| 必须配闸门 (软层非银弹)  | 2606.14589 事前预防 0%; 软前缀 54–90% 翻转 [17]                                  |
| 按模型标定格式/容量     | 12 模型提示研究 [15]; 指令层级差异 [13][14]; IFScale 失效模式分化 [2]                     |

### 参考文献

“The Instruction Complexity Cliff” (2026) ——平均稳定满足约 3.3 个并发约束。 <https://tianpan.co/blog/2026-04-17-instruction-complexity-cliff-llm-compliance>

Arize, “Models got an order of magnitude better at following instructions in one year” (IFScale 2026 复测, 2026-05) ——前沿模型拐点推至 ~2000; DeepSeek 经典丢弃、Claude 拒答、Gemini 空转三种失效模式。 <https://arize.com/blog/llm-instruction-following-benchmark-2026/>

Anil et al. (Anthropic), “Many-shot Jailbreaking” (NeurIPS 2024) ——对话历史示范的行为塑造服从幂律。 <https://www.anthropic.com/research/many-shot-jailbreaking>

“Negative Prompting: Telling an LLM What Not to Do” (2026) 。 <https://ai-tldr.dev/learn/prompt-engineering/prompting-basics/negative-prompting-constraints-llm/>

Zhao et al., “ExpeL: LLM Agents Are Experiential Learners” (AAAI 2024) 。 <https://arxiv.org/abs/2308.10144>

Chen et al., “Reasoning Models Don’t Always Say What They Think” (arXiv 2505.05410); “How Faithful Is Chain-of-Thought Reasoning” (arXiv 2603.22582)。

“Experience-Driven Suppression of Overused Checking in LLM Reasoning” (arXiv 2602.03485)。

“Understanding Memory Confabulation in Reflexive Agents” (arXiv 2605.29463)。

Gloaguen et al. (ETH Zurich), “Are Repository-Level Context Files Helpful for Coding Agents?” (2026)。 <https://arxiv.org/html/2602.11988v1>

OpenAI×Apollo Research, “Stress Testing Deliberative Alignment for Anti-Scheming Training” (2025)。 <https://www.apolloresearch.ai/science/stress-testing-deliberative-alignment-for-anti-scheming-training/>

“Supporting Effective Goal Setting with LLM-Based Chatbots” (arXiv 2602.08636) ; Gollwitzer (1999) implementation intentions。

“Diagnosing Premature Commitment in LLM Agents” (arXiv 2606.22936)。

OpenAI, “Improving instruction hierarchy in frontier LLMs” (2026-03) ——IH 训练提升提示注入抵抗。  
<https://openai.com/index/instruction-hierarchy-challenge/>

“Just Ask: Curious Code Agents Reveal System Prompts in Frontier LLMs” (arXiv 2601.21233) ——41  
模型；闭源 4.8 轮 vs 微调 1.3 轮；LLaMA 系层级弱。<https://arxiv.org/html/2601.21233v1>

TR Labs, “Optimizing Prompts Across LLMs” (2025) ——12 模型：few-shot 9/12 有效、格式偏好按家族  
分化。<https://medium.com/tr-labs-ml-engineering-blog/optimizing-prompts-across-llms-a-comprehensive-overview-part-1-3ae4b0a2ff51>

“An Empirical Evaluation of Prompting Strategies for LLMs in Zero-Shot Clinical NLP” (JMIR  
2024) ——GPT-3.5/Gemini/LLaMA-2  $\times$  6 种提示策略交互显著。<https://pmc.ncbi.nlm.nih.gov/articles/PMC11036183/>

Chen et al. (2026, 经 Vector Labs 报道) ——软前缀以 54–90% 翻转率改变 Qwen3.6-35B/Gemma 4 31B  
的正确推理。<https://vector-labs.ai/insights/why-prompt-engineering-is-not-a-reliability-strategy-what-llm-behavioral-research-tells-engineering-leaders>